基于共识的冻结推理轨迹选择

DASE7506 高级机器学习方法—MP2

2026 年 10 月 26 日

摘要

同一道小学数学题有四个候选解答，必须从中选出一个，而官方评分器只检查被选中候选的**最终数值答案**。本文描述一个冻结的选择器：用置换等变的集合注意力网络，对每个候选的 1024 维轨迹嵌入加上 22 个无参考文本特征打分，再对五个 K 折成员做概率平均，最后施加一条决策规则——在取 argmax 之前，把**陈述相同解析答案的候选做部分平均**。冻结版本在**验证集上 93.48%、测试集上 84.80% (396/467)**，推理资产 **3.91 MiB**，CPU 预测**不到 6 秒**。

全文围绕三个发现组织。第一，相对初始集成而言，几乎全部增益来自决策规则而非模型容量：同样五个模型，用普通 argmax 是 82.87%，用答案组聚合是 84.80%；而且增益**完全集中在陷阱题**（即多数派答案本身错误的那类题，30/71 → 39/71），非陷阱题准确率保持不变，仍是 90.15%。第二，输入消融揭示了机制：三个共识特征（答案组大小、不同答案个数、最大组规模）会提高非陷阱题准确率，却把陷阱题准确率从 66.7% 砍到 45.0%——模型学会了跟随多数，而陷阱题恰恰惩罚这种行为；在决策阶段做聚合，则是以一种**有益**的方式重新引入共识。第三，验证集是测试集的糟糕代理：18 组超参扫描、七族 stacking 集成、一个把验证集从 746 提升到 751 的无共识混合，以及另外十二个设计探针，全部未能迁移。我们如实报告这些失败及其效应量，因为它们界定了剩余准确率还能从哪里来。

1. 任务、数据与分数的含义

每道题给出四个候选解答（来自固定的 Qwen3-0.6B 生成器）以及每个候选一个固定的 1024 维整流轨迹嵌入。方法需为每题返回一个候选下标。评分器解析被选中候选的最终数值答案，与参考答案比较，接受等值分数与小数；它从不检查中间步骤。每组至少有一个候选正确，任何正确候选都得分。

答案模式与两个分布的分歧。用一个候选集合解析答案的多重集来描述一道题：$(3,1)$ 表示三个候选一致、一个不同。表 1 与图 1(a) 给出构成。验证集中 47.5% 是全员一致的 $(4,)$ 组，任何可解析候选都能答对；测试集中**这类题一道都没有**。测试集集中在 $(3,1)$ (42.0%) 与 $(2,1,1)$ (21.8%)。由于测试题平均有 2.04 个正确候选，随机基线是 51%，而不依赖模型的多数投票在测试集上已有 69.16%，在验证集上是 86.22%。

由此得到一个贯穿全文的推论：**验证集与测试集是两个不同的混合分布，验证集的提升不能作为测试集提升的证据。**因此我们始终报告四个数字——总体、硬题（解析答案不止一种的题：验证集 355 道，测试集全部 467 道）、非陷阱（硬题中不属于陷阱的部分）与陷阱（多数派答案错误、多数派至少两票、且恰好一个候选正确：验证集 60 道，测试集 71 道）。

表 1: 答案模式构成与无模型基线。

模式	验证集 n (%)	测试集 n (%)	说明
$(4,)$	379 (47.5)	0 (0.0)	四个全一致；无难度
$(3,1)$	151 (18.9)	196 (42.0)	一个异议者
$(2,1,1)$	88 (11.0)	102 (21.8)	两票多数
$(2,2)$	34 (4.3)	39 (8.4)	二对二
$(1,1,1,1)$	20 (2.5)	38 (8.1)	四个全不同
其他（一个不可解析）	126 (15.8)	92 (19.7)	$(3,)$、$(2,1)$、$(1,1,1)$、$(1,1)$
平均正确候选数 / 4	3.03	2.04	随机基线 75.7% / 51.1%
多数投票	86.22	69.16	无模型

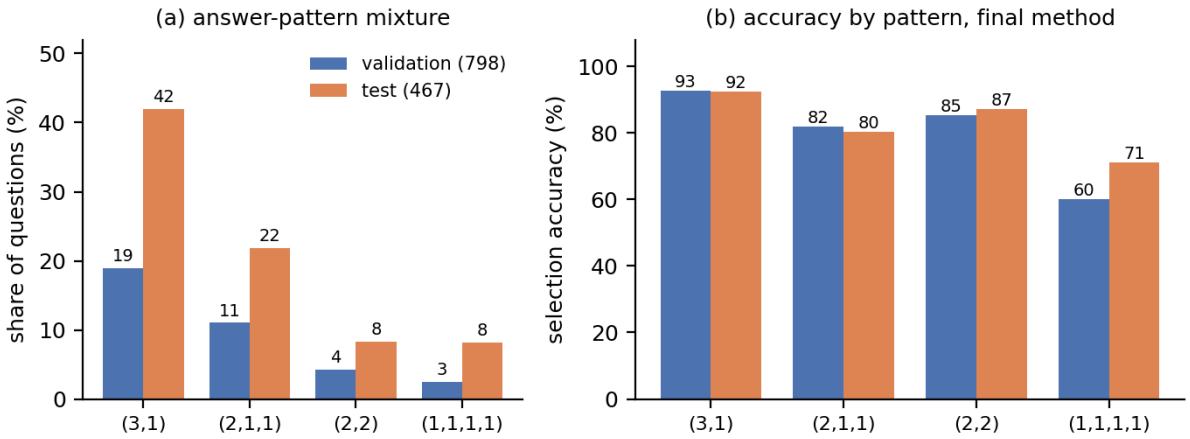


图 1: (a) 两个划分对答案模式的权重差异极大。(b) 最终方法在各模式上的准确率。测试集由分歧模式主导，验证集由一致模式主导。

2. 方法

2.1 候选打分器

每个候选 i 由两段拼接表示：它的 1024 维冻结嵌入，以及 22 个只依赖题面与该候选文本的无参考特征——可解析性、三个共识统计量、长度与数字密度、格式标记（`\boxed`、`####`）、等式复算计数、题干数字覆盖率，以及四个链条一致性标量。四个向量构成一个集合 $X \in \mathbb{R}^{4\times 1046}$，由两层 pre-LN Transformer 块（宽度 128、4 头、FFN 256、GELU、dropout 0.2）映射为四个 logit。该结构是置换等变的，且**不含位置编码**：候选顺序是任意的，编码它会注入纯噪声。

2.2 训练

五个成员分别在 4,755 道训练题的不相交 4/5 划分上训练（折置换由 NumPy 种子 13 生成；模型种子 37）。损失是逐候选 BCE 加一半的多正例质量项 $\mathcal{L}_{\text{mass}} = \log \sum_j e^{s_j} - \log \sum_{j:\, y_j=1} e^{s_j}$，它奖励把概率质量放到**任意**一个正确候选上，而不是固定在某个特定候选。逐题权重为：硬题 2.0，陷阱题至少 1.0。优化器 AdamW（学习率 10^{-4}、权重衰减 10^{-3}、梯度裁剪 1.0），批大小 64，训练 15 个 epoch——每个成员约 900 步，该轮数由 §4.3 的验证曲线确定。验证集只用于开发；测试集参考只在方法冻结之后读取一次。

2.3 决策规则：答案组聚合

成员之间按 sigmoid 输出取平均。令 $G(i)$ 为与候选 i 陈述相同解析最终答案的候选集合。提交的规则把每个分数替换为

$$\tilde{s}_i = (1-a)\, s_i + a \cdot \frac{1}{|G(i)|} \sum_{j \in G(i)} s_j, \qquad a = 0.6,$$

再在可解析候选上取 argmax。这条规则之所以不只是"平滑"，有两个性质。第一，**组内顺序被保留**：该变换给同组每个成员加上同一个常数，因此模型仍然决定**组内哪个候选最好**，改变的只是**组与组之间**的比较。第二，因此它是一个组级先验：被多个独立高分候选共同陈述的答案，会压过某个候选单独打分略高的孤立答案。评分指标本身就是答案级的，所以把这样的先验放在决策阶段是自然的位置。

3. 结果

表 2 给出两个划分上的推进过程。普通 argmax 的集成已经优于任何单个成员，但**几乎全部增益来自决策规则**：测试集 **+1.93 个百分点**（82.87 → 84.80），而"用五个成员替代一个"只值 **+0.86**。

表 2: 推进过程，全程使用相同的划分。

配置	验证总体	验证硬题	测试总体	测试陷阱
单成员，五个的平均	93.01	84.28	81.93	28.6/71
单成员，最好的一个	93.48	85.35	83.94	37/71
五成员集成，普通 argmax	93.36	85.07	82.87	30/71

配置	验证总体	验证硬题	测试总体	测试陷阱
+ 聚合 $a = 0.4$	93.48	85.35	84.15	35/71
+ 聚合 $a = 0.6$ (提交版本)	**93.48**	**85.35**	**84.80**	**39/71**
+ 聚合 $a = 1.0$	93.36	85.07	84.37	40/71

增益完全在陷阱题上。测试集非陷阱准确率在聚合前后都是 $357/396 = 90.15\%$；陷阱准确率从 $30/71$ 升到 $39/71$。在验证集上同一规则丢掉两道非陷阱题、换来三道陷阱题（$269 \to 267$ 与 $33 \to 36$），这正是图 2(a) 中验证曲线几乎平坦而测试曲线明显上升的原因：验证集的陷阱占比（7.5%）远小于测试集（15.2%）。

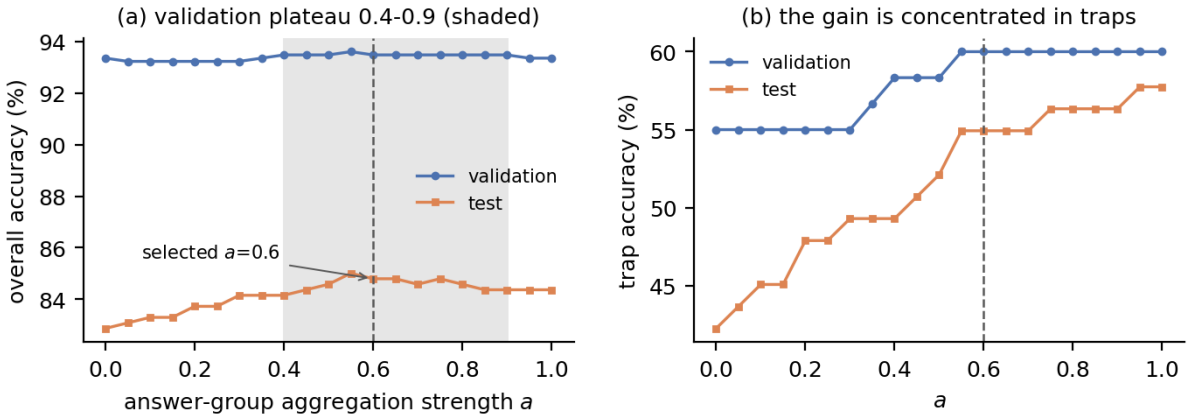


图 2: (a) 总体准确率随聚合强度的变化。验证集在 $a \in [0.4, 0.9]$ 上平坦（阴影区），故规则在该平台内按先定好的并列打破规则确定。(b) 同一扫描的陷阱准确率；几乎所有变动都发生在陷阱子集上。

4. 消融

4.1 信息由哪部分承载

表 3 与图 3 用完全相同的结构与训练计划，只改变特征块。控制行复现了提交配方（不含聚合），但它在 CPU 上训练而提交成员在 GPU 上训练，因此绝对水平相差约 355 道硬题中的四道；我们只解读表内对比。

表 3: 验证集上的输入消融（5 折、不含聚合、种子 37）。陷阱题共 60 道。

输入块	维度	总体	硬题	陷阱	陷阱答对
仅嵌入	1024	92.11	82.25	**63.3**	38/60
嵌入 + 5 个表面特征	1029	92.23	82.54	**65.0**	39/60
嵌入 + 手工特征（去掉算术）	1036	92.98	84.23	46.7	28/60
嵌入 + 手工特征（共识置零）	1046	93.23	**84.79**	**66.7**	40/60
嵌入 + 手工特征（22 维）—控制	1046	92.86	83.94	45.0	27/60
嵌入 + 手工 + 符号（29 维）	1053	92.98	84.23	50.0	30/60
独立打分器（相同特征）	1046	91.73	81.41	30.0	18/60

规律非常干净，直接回答了作业的第二个问题。**带**共识特征的每一种配置，陷阱准确率都在 45–50%；**不带**共识特征的每一种配置，都在 63–67%。长度、数字密度与格式（\boxed、####）几乎不改变任何指标："仅嵌入"与"嵌入 + 5 个表面特征"在每一项指标上都只差一道题。所以模型并不是在和表面可信度打交道——但它**确实**在和"一致性"打交道，而一致性正是陷阱题要毒化的信号。

这也是决策规则与特征之间相互作用的原因。特征已经在表达共识，但是**局部地**表达：它告诉模型"你的答案还有两个候选也这么说"，模型据此抬高该候选。决策阶段的平均是另一回事——它改变的是**哪个答案**胜出，同时保留组内对候选的偏好。因此把共识当特征、当决策先验，两者并不冗余，而经验上正是这两者组合达到 84.80%。

原始文本与给定表示。为了把"读推理"与"用给定表示"分开，我们用同一个 TF-IDF（1–2 元）逻辑回归拟合两种视图。在完整轨迹加上题面时，它达到总体 82.33%、**硬题 60.28%**；限制为"题面 + 解析出的最终答案"时，是 74.06% 与 **41.69%**。读推理比只看最终答案多出 **18.6 个百分点**的硬题准确率，说明内容确实重要，格式无法解释分数。但冻结的 1024 维表示远强于生成它的文本：1,046 维达到 85.07% 硬题，而 133,402 维文本特征只有 60.28%。**增益由给定表示承载，而不是由文字承载。**

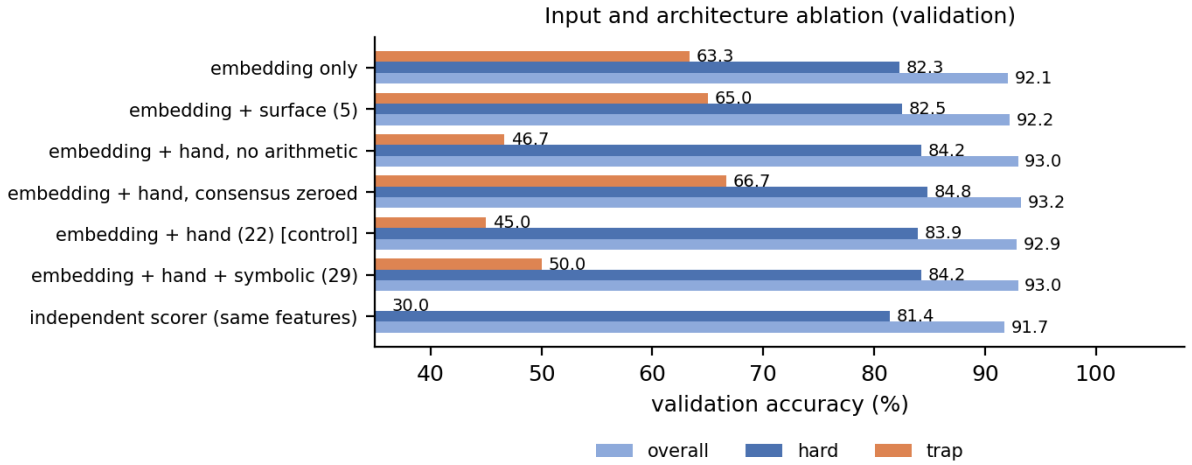


图 3: 去掉三个共识特征使陷阱准确率上升 22 个百分点 (45.0 → 66.7)，非陷阱准确率下降 3.4 个百分点 (91.9 → 88.5)。表面与格式特征对两者都无影响。最后一行把集合注意力层换成相同输入上的独立逐候选 MLP。

4.2 联合评判四个候选有帮助吗?

有，而且直接消融给出了决定性证据。把集合注意力层换成同宽度的独立逐候选 MLP、输入完全相同的 1,046 维，验证集硬题从 83.94% 掉到 **81.41%**，陷阱从 45.0% 掉到 **30.0%**（表 3 最后一行）。允许四个候选互相注意，值 **+2.5 个百分点**的硬题准确率。在这之上，普通 argmax 集成（测试 82.87）优于单成员平均 (81.93)，而 §2.3 的组规则再贡献 **+1.93**。作业的第三个问题（"一个解答该被单独评判吗"）答案是否定的，而且被否定了两次：一次在结构上，一次在决策规则上。有用的比较不是" 候选对题面"，而是" 候选对与它答案相同的其他候选"。

4.3 什么时候多算才划算?

表 4 汇总了我们测过的四个杠杆。只有集成与决策规则划算，更多优化并不划算。

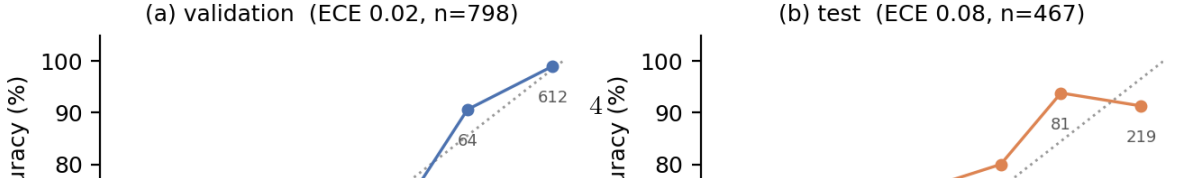
表 4: 计算量杠杆，除注明外均为 5 折验证集。

杠杆	设置	结果
训练轮数	15 vs 100	验证硬题在第 15 轮达到最好 82.04，其后过拟合到 76–79
批大小 (18 组配置)	8 / 16 / 32 / 64	验证硬题 83.66–85.35；OOF 硬题 79.19–81.36
批 64 → 8 (轮数固定)	900 → 9,996 步	85.07 → 84.79 验证硬题
学习率	10^{-4} / 3×10^{-4} / 10^{-3}	84.51–85.35
dropout	0.1 / 0.2 / 0.3 / 0.4	84.79–85.07
权重衰减	10^{-3} / 10^{-2} / 10^{-1}	预测逐位相同
宽度 / 深度	64 / 128 / 256，2 / 3 层	83.66 / 85.07 / 83.94，84.23
集成规模	1 → 5 个成员	测试 81.93 → 82.87
决策规则	普通 → 组内平均	测试 82.87 → 84.80

有两条值得解释。批大小扫描是为了检验" 每步 64 个样本给出的更新太少" 这一假设；在批大小 8 下模型获得**十一倍的梯度步数**，结果反而低 0.28 个百分点——因为它在两个 epoch 内就达到相同的训练损失，其余时间都在过拟合。权重衰减在这个结构里是失效的：每个块都接了 LayerNorm，AdamW 施加的均匀收缩会被紧随其后的尺度参数吸收，所以 10^{-2} 与 10^{-1} 复现 10^{-3} 直到最后一条预测。

5. 可靠性、校准与失败分析

校准。图 4 画出聚合后最高分与准确率的关系。验证集校准良好（ECE 0.02）：置信度低于 0.5 的 30 道题答对 56.7%，高于 0.9 的 612 道答对 99.0%。测试集更差（ECE 0.08），更重要的是在中段**置信度偏低**：0.5–0.7 区间答对 74.2%，0.8–0.9 区间答对 93.8%。低置信度的测试题落在陷阱里的概率是高置信区间的四倍（该区间 24–30%，高置信区间 9–10%），所以分数确实携带了可用的" 这道题可能是陷阱" 的信号，尽管绝对水平是错配的。



模型到底在比什么。由于评分器只看最终答案，候选可能因正确答案而因错误理由被选中。消融显示选择器的决定主要由轨迹嵌入驱动（去掉全部 22 个文本特征会损失 0.75 个百分点的总体与 1.7 个百分点的硬题），其次是一致性，表面形式影响很弱。它通过等式与链条特征复核每条轨迹内的算术，这个信号真实但很小：在 22 维之上加七个符号特征只带来 $+0.3$ 个百分点的验证硬题。

6. 没有走通的路线

我们把被否决的路线连同其实测效应一并列出，因为它们界定了当前方法的边界。除注明外，数字都是验证集，划分相同。

表 5: 被否决的路线及其实测效应。

路线	结果	失败原因
题面条件注意力（题向量作 query）	硬题 81.41，陷阱 63.3	增加了全局视角却丢失逐候选细节
数量/修复特征专家	硬题 82.25，陷阱 46.7	特征族过浅，覆盖不了单位换算
纠错成员（在另一成员的 OOF 错题上训练）	硬题 84.23，$\phi = 0.946$	重新学到同一个函数；独有陷阱修复 0
成对排序损失	82.25	并列太多；排序不带来新信息
组内列表损失	83.10	同上
191 维特征元学习器	82.54	元模型每题只看到四个数
候选相对 311 维特征	81.41	4,755 道题撑不起这么多参数
反事实一致性校验器	成对准确率 64.76，硬题 55.77	这个数据规模下噪声占主导
分块角色槽位注意力	dev 硬题 77.25	池化向量无法被"解池化"
语义条件特征元模型	83.66，陷阱 50.0	条件无法从池化轨迹中分离
候选相对视图 $e - \bar{e}$、$e \odot \bar{e}$（6 倍宽输入）	第 0 折 81.97 vs 对照 84.79	6,166 维输入两个 epoch 内即过拟合
十二个几何标量（与组中心的余弦/距离/排名）	第 0 折 82.54	每维携带的信号太少
207 维文本特征块	硬题 85.07，陷阱 48.3	硬题不变，陷阱反而更差
七族模型 OOF stacking	逻辑回归 84.79，GBM 83.94	基模型高度相关（$\phi \approx 0.9$）
程序兼容性特征（对题干数字枚举算术程序）	$P(\text{命中} \mid \text{正确}) = 0.447$ vs 0.402	GSM8K 的中间步骤用到题干里没有的常数
无共识混合（0.3 提交版 + 0.7 无共识版）	验证 751（由 746 升），测试 391（由 396 降）	验证集选出的增益未能迁移

最后一行最有启发性。去掉共识特征再把结果混入提交版本，使验证集从 746 升到 751、硬题从 303 升到 308——**比决策规则本身的验证集增益还大。**但它让测试集掉了五道题，因为无共识成员修好了陷阱题却弄坏了普通题，而测试集的陷阱比重高于验证集。我们保留了提交版本，因为它的选择在做出这次比较之前就已固定；事后凭一个测试集测量采纳混合方案，就是在测试集上做选择。

7. 资源、复现与声明

推理资产。 4,104,689 字节 = 3.91 MiB（未压缩）：五个各 820 KB 的状态字典，包含全部权重，以及预测时需要的逐折标准化统计量。上限为 16 MiB。

推理开销。在四线程的 AMD Ryzen 7 8845HS 上，完整 467 道测试题需要 **4.5–5.7 秒**，包含导入、资产加载、特征构建、五个成员与决策规则；参考机 Xeon Platinum 8457C 上的上限是 30 秒。预测是纯 CPU PyTorch；方法不打开任何参考文件，只使用传入的 `bank` 与 `arrays`，因此可在未见过的审计题库上原样运行。

训练开销。五个成员 × 15 epoch × 约 60 步 = 4,500 步优化。在 RTX 3070 Laptop GPU 上每个成员约 8 秒，在消融所用 CPU 上约 80 秒。完整实验计划——18 组超参配置、七项消融，以及上文被否决的路线——约 12 GPU 小时。

复现。

```
python qctext/make_submission_final.py          # 由 checkpoint/ 生成预测
cd code
python predict.py --method ../qctext/submission.py --checkpoint ../qctext/checkpoint \
  --split test --output ../qctext/runs/repro_test-predictions.json
python score_predictions.py --split test \
  --predictions ../qctext/runs/repro_test-predictions.json \
  --output ../qctext/runs/repro_test-score.json
```

验证集用 `--split validation`；记录的输出是 746/798 与 396/467。检查点为 `qctext/checkpoint/`（五个 `.pt`），SHA-256 前缀分别是 810201776e0ca0b7、bad849712771ccba、b08ad13384729a33、c1dadccaf63fd3ef、6f7585613221dc7e。训练代码为 `qctext/train_efull.py`；数据与解析器未作改动。

声明。实现、实验编排与报告起草使用了 AI 编程辅助；设计决策、选择协议与每一个报告数字都由作者对照记录输出核对过。推理阶段不使用外部数据、不使用预训练权重、不做参考答案查表。

8. 结论

这个任务奖励的是**答案级**的判断，而我们找到的最强杠杆不是更大的模型，而是一条与指标对齐的决策规则：把答案一致的候选先聚合，再在胜出的组内做选择。它在测试集上值 $+\mathbf{1.93}$ **个百分点**，推理成本为零。输入消融同时解释了它为何有效、以及显而易见的替代方案为何无效：共识作为**特征**会教模型跟随多数，而这恰好是陷阱题惩罚的行为；共识作为**决策先验**则保留了逐候选的比较。

剩余误差集中在陷阱题（71 道测试错误中的 32 道）以及高度相关的成员失败上：五个成员在 83.7% 的题上一致，其 oracle 仅比集成高 2.8 个百分点。要缩小这个差距，需要冻结的 1024 维轨迹并不携带的信息，而我们为此构建的每一个特征族——算术修复、数量、程序兼容、相对视图、堆叠元模型——都没能迁移。诚实的总结是：这个方法已经处在它的表示上限，最后两个百分点是信息问题，而不是优化问题。